

面向路侧部署的单目视觉 3D 交通感知系统

--基于 ELF-RV1126B

摘要

由于传统的路侧三维交通感知系统高度依赖激光雷达，存在设备造价昂贵、施工安装繁琐及维护成本高昂等痛点，开发基于单目相机的低成本 3D 感知系统具有重要的工程实用价值。本项目基于飞凌 ELF-RV1126B 开发板，实现了一套面向路侧部署的低成本单目 3D 交通感知系统。系统的核心是 N-RTM3D（NPU-adapted RTM3D）检测模型--一种针对嵌入式 NPU 进行深度适配与优化的单目 3D 目标检测算法（基于 CenterNet 框架改进）。模型采用 ResNet-18 作为骨干网络，通过预测车辆 3D 包围框在图像上的投影关键点，反解出车辆在三维空间中的位置、尺寸和朝向。

针对边缘端 NPU 的算子支持与访存带宽瓶颈，我们对 RTM3D 检测器的网络结构进行了深度适配与重构。首先，移除了硬件不支持的形变卷积（DCNv2），采用标准密集卷积进行替代；其次，设计了多任务分支的共享 Stem 过渡层（单个 3x3 卷积进行 256ch 至 64ch 通道压缩），使得后续 9 路预测头能够采用极轻量化的 1x1 卷积，大幅降低了 NPU 访存带宽消耗，实现了推理时延的减半。此外，在后处理端，我们针对路侧俯视角优化了 3D 几何求解方程，引入车顶关键点投影约束以增强抗遮挡测距鲁棒性，并利用 NumPy 矩阵运算实现了 3D 坐标的级联向量化并行求解，消除了 CPU 串行计算瓶颈。

在 200 帧 DAIR-V2X 路侧验证集上实测，系统端到端处理速度约 3.60 FPS（算法运算速度为 4.24 FPS），全局 F1-Score 为 86.00%（置信度阈值 $\text{conf}=0.35$ ）。在 0-30 米近距离区域，召回率为 86.96%，平均测距误差 1.46 米。系统连续运行 40 分钟以上，芯片温度稳定在 58.4°C 左右，CPU 占用约 51%（单核），内存占用约 150-180MB，运行表现稳定。

第一部分 作品概述

1.1 功能说明

本系统的核心功能是：从路侧单路固定的摄像头画面中，检测出车辆、行人、骑行者，并估算其在三维空间中的位置（X, Y, Z 坐标）和朝向（偏航角）。

系统对每一帧输入图像进行如下处理：

- 1. 图像预处理：**对输入图像进行自适应对比度增强（CLAHE）和自动白平衡，改善夜间或逆光等不良光照条件下的图像质量。
- 2. NPU 推理：**将预处理后的图像送入 NPU 运行 N-RTM3D 模型，输出包含目标位置、投影关键点、尺寸、朝向等信息的 9 组特征图。
- 3. 3D 坐标解算：**在 CPU 端，根据模型输出的 2D 投影点坐标和相机内参矩阵，通过求解线性方程组，计算出每个目标在相机坐标系下的三维位置和偏航角。

- 4. 多目标跟踪：**使用基于 IoU 匹配的跟踪器维护目标 ID，保证检测结果在时间上的连续性。
- 5. 结果输出：**支持两种运行模式——在 7 寸 MIPI 屏上实时呈现检测画面（含 3D 框、鸟瞰图、热力图等），或以无界面模式运行，将检测结果以 JSON 格式输出或通过网络发送。

1.2 应用场景

本系统面向智能交通与车路协同领域，主要应用场景包括：

- 1. 路口车辆感知：**部署在路口杆件上，实时检测路口车辆的三维位置和数量，为交通信号控制和车路协同提供感知数据支持。
- 2. 交通流量统计：**统计路口车流量、平均车速、车辆类型分布等信息，辅助城市交通规划与管理。
- 3. 面向 V2X 的高精度车辆平面定位：**输出车辆在地面鸟瞰图下的物理平面坐标。该高精度平面定位坐标经由跟踪器持续平滑，形成连续行驶轨迹，可直接对接车路协同（V2X）路侧单元，为自动驾驶车辆提供超视距与盲区协同感知支持。

1.3 主要技术特点

- 1. 板载 NPU 硬件原生运行（N-RTM3D）：**模型移除了边缘端硬件不支持的形变卷积（DCNv2）算子，改用标准密集卷积，并引入共享 Stem 过渡层降低特征图通道数，从而实现板载 NPU（RKNPu）的硬件原生支持。经 INT8 量化后，单帧 NPU 推理耗时约 189.7ms。
- 2. 向量化批量几何后处理：**三维空间位置解算采用基于 NumPy 矩阵运算的批量处理机制，对图像内的所有目标进行一键向量化级联求解，消除多目标场景下的 CPU 串行耗时瓶颈，后处理时延约 35.9ms。
- 3. 自适应图像质量增强：**前处理阶段实时评估视频帧的亮度和对比度，对夜间或强逆光等暗光场景自动应用限制对比度自适应直方图均衡化（CLAHE）以及白平衡增强，单帧预处理时延约 10.0ms，提升了全天候条件下的检测鲁棒性。

1.4 主要性能指标

指标	数值	说明
检测帧率（无显示）	3.60 FPS	端到端，含预处理+推理+后处理
检测帧率（带屏幕显示）	3.10 FPS	含 Dashboard 渲染和屏幕输出
全局 F1-Score(conf=0.35)	86.00%	conf=0.35，DAIR-V2X 路侧验证集
近区(0-30m)召回率	86.96%	漏检率 13.04%
近区(0-30m)测距误差	1.46 米	3D 深度方向平均误差
NPU 推理耗时	189.7 ms	占总时延的 80.5%
CPU 后处理耗时	35.9 ms	含 3D 解算和跟踪
图像预处理耗时	10.0 ms	含 CLAHE 和缩放
CPU 占用率	51%（单核）	折合四核总算力的约 12.7%
内存占用	150-180 MB	约占总内存的 3.8%-4.6%
稳态工作温度	58.4 °C	远低于 80°C 降频阈值
整板功耗（满载）	3.4 W	5V/0.68A

1.5 创新点

- 1. 共享 Stem 网络重构：**用标准卷积替代 NPU 不支持的 DCNv2，设计通道压缩的共享 Stem 层，解决多检测头访存瓶颈，推理时延缩减 50%。
- 2. 抗遮挡车顶几何约束解算：**抗遮挡车顶几何约束解算：过滤易受遮挡和阴影干扰的底部 4 个角点，筛选提取稳定的车顶 4 角点与中心点进行求解。
- 3. 后处理向量化加速：**用 NumPy 矩阵批量并行解算替代逐元素串行循环，实现多目标级联并行求解。

1.6 设计流程

项目的整体工作流程如下：

- 1. 数据准备：**使用 DAIR-V2X 路侧数据集（1920×1080 图像），将标注转换为适用于单目 3D 训练的相机坐标系标签。
- 2. 模型训练与结构调优：**在 PC 端用 PyTorch 训练重构后的模型，采用 ResNet-18 骨干网络，使用 Adam 优化器，通过调整损失权重和掩码阈值进行收敛优化。
- 3. 模型转换：**PyTorch → ONNX → RKNN（INT8 量化），利用校准数据集进行量化。
- 4. 板端部署：**在开发板上通过 rknn-toolkit-lite2 载入模型，并利用 NumPy 编写向量化几何后处理模块。
- 5. 精度与性能分析：**在验证集上测试多种置信度阈值和距离范围的精度，对系统延迟分布、温度和功耗进行稳定评估。

第二部分 系统组成及功能说明

2.1 整体介绍

系统由硬件和软件两部分组成。硬件上，ELF-RV1126B 开发板作为主控，通过网口接入摄像头视频流或读取本地图像数据，通过 MIPI 接口连接 7 寸显示屏用于现场调试。软件上，整个检测流程在开发板上完成，包括图像预处理、NPU 推理、CPU 后处理和结果输出。

系统总体架构与数据流图如下所示：



图：系统数据流图

系统运行时的实时监控面板 (RTM3D Dashboard) 如下图所示，可直观呈现 3D 检测框、鸟瞰图及 NPU 输出的热力图特征：




图: Dashboard

2.2 硬件系统介绍


2.2.1 硬件整体介绍

主控板为飞凌 ELF-RV1126B 开发板，核心参数如下：

项目	参数
处理器	瑞芯微 RV1126B, 4 核 ARM Cortex-A53, 主频 1.6GHz
NPU 算力	3.0 TOPS@INT8
内存	1GB LPDDR4
存储	8GB eMMC
视频编解码	硬件 H.264/H.265
网络	千兆以太网 (RTL8211F)
显示	MIPI-DSI 接口

2.2.2 机械结构

本系统配置了 7 寸 MIPI 触摸屏作为现场可视化数据终端。为了保障在调试与触摸交互过程中的物理稳定性，并防止屏幕排线受外力牵拉，屏幕装配有专用的物理固定面板进行限位与支撑。



图：7 寸 MIPI 显示屏固定面板结构尺寸图

面板主要结构参数如下：

外廓尺寸：固定面板整体长为 190.00mm，宽为 130.00mm，四角采用圆弧防刮伤设计（圆角半径 R5）。

视窗区域：面板中心开设有 154.21mm × 97.00mm 的矩形视窗，该开孔尺寸与 7 寸 LCD 屏幕的有效显示区域相匹配，确保显示画面无边缘遮挡。


定位安装：面板的四个角设有定位螺栓安装孔，用于将屏幕组件稳固锁紧于主设备箱体或路侧支撑架上，以承载触摸交互时的操作下压力。

2.2.3 电路模块

本系统基于飞凌提供的 ELF-RV1126B 单板硬件平台进行集成。以下结合开发板的底板原理图，对系统运行涉及的千兆网口数据接收、MIPI-DSI 视频输出以及电源转换三个核心电路模块进行逐级分析说明。

1. 千兆网口收发电路模块（视频流输入通道）

系统通过千兆以太网接口接收路侧相机的实时 RTSP 视频流。网口电路的核心为板载的千兆以太网 PHY 芯片 U17 (MAE0621A-Q3C)，该芯片用于执行网络物理层（PHY）的数据收发与转换。



图：千兆以太网收发电路原理图

关键信号线与引脚定义：


ETH_TXD0_M0 ~ ETH_TXD3_M0 / ETH_RXD0_M0 ~ ETH_RXD3_M0：RGMII 接口的高速数据发送与接收数据线，负责媒体访问控制器（MAC）与 PHY 芯片之间双向并行数据传输。

ETH_TXCTL_M0 / ETH_TXCLK_M0：发送控制信号与发送时钟同步信号线，提供 125MHz 的基准同步时钟，确保千兆数据流的稳定对齐。

电路运作机理：摄像头采集的 H.264/H.265 编码格式的高清画面数据，通过 RJ45 网口接入后，经 MAE0621A-Q3C 进行物理层解码，并利用 RGMII 总线将数据搬运至 RV1126 处理器的 GMAC 控制器中，完成输入端的视频流解析。

2. MIPI-DSI 显示接口电路模块（控制面板输出通道）

系统实时渲染的 3D 感知结果与可视化 Dashboard 面板通过板载的 30-pin FPC 插座 P4 输出至 7 寸 LCD 液晶显示屏上。




关键信号线与引脚定义:

MIPI_DPHY_DSI_TX_CLK_P/N: DSI 差分时钟信号线，用于维持数据线差分信号的建立时间与保持时间对齐。

电路运作机理：主控芯片内部生成的显示缓冲区（Frame Buffer）数据，经由 RV1126 处理器的 MIPI-DSI 发送控制器进行串行化，通过高速差分信号对传输至 LCD 控制芯片，实现实时的监控画面与数据面板渲染显示。

系统算法在板端全速运行时，整体峰值功耗约 3.4W。为保证主控芯片的 NPU 单元及外设在高吞吐率下稳定工作，系统底板设计了多级降压与稳压供电电路。主供电通过 Type-C 接口 J1 输入 5V 直流电压，并使用同步降压芯片 U5 (MP2147GD) 将其转换为系统所需的 3.3V 电压轨。



图：系统电源转换与稳压电路原理图

关键信号线与引脚定义：

VCC_5V：主电源总线，外接适配器输入的直流 5V。

VCC_3V3：系统 3.3V 系统电压轨，通过 U5 降压输出，用于网口芯片、LCD 接口等外设供电。

VDD_NPU / VDD_CPU：芯片内部核心供电电压轨，通过核心板上的电源管理单元（PMIC）精密控制，供给 NPU 神经网络加速器和 CPU 内核。

电路运作机理：外部 5V 直流电接入后，首先通过高频 DCDC 降压器转换为 3.3V 和 1.8V 系统电压。当 NPU 全速执行算子导致芯片瞬态电流剧增时，外围旁路滤波电容与高频电感进行快速能量释放，确保核心供电的纹波在安全范围内，保障系统连续运行的稳定性。


2.3 软件系统介绍

2.3.1 软件整体介绍

板端软件运行在 Debian Linux 系统上，核心依赖包括 rknn-toolkit-lite2（NPU 驱动）、NumPy（数值计算）和 OpenCV（图像处理）。整个推理流水线采用 Python 实现，主要包含三个核心模块：图像预处理模块、NPU 推理模块（N-RTM3D）以及 CPU 后处理与多目标跟踪模块。

2.3.2 N-RTM3D 模型架构

N-RTM3D（NPU-adapted Real-time Monocular 3D Detection）是本系统的核心检测模型。它是在原版 RTM3D 算法基础上针对边缘端 NPU 算子支持与精度保持进行深度优化后的单目 3D 目标检测模型，其网络结构图如下所示：



图：N-RTM3D 模型网络架构图

具体结构分述如下：

（1）骨干网络：ResNet-18

使用 ImageNet 预训练的 ResNet-18 提取图像特征。ResNet-18 由 4 组残差模块组成（每组 2 个 BasicBlock），将输入图像逐步下采样 32 倍，输出 512 通道的特征图。选择 ResNet-18 是因为它在精度和计算量之间取得了较好的平衡，且所有操作（卷积、BN、ReLU、池化）都能被 NPU 完整支持。

（2）上采样解码器：3 层反卷积

骨干网络输出的特征图分辨率较低，通过 3 层转置卷积（ConvTranspose2d，步长为 2）逐步上采样 8 倍，得到 256 通道、分辨率为输入 1/4 的特征图（即 128×424）。与原版逐渐缩窄的通道配置相比，这里全部保持 256 通道以保留更丰富的高层空间语义。

（3）9 个预测头

在反卷积解码器输出的 256 通道共享特征图上，为了降低计算量并适配端侧 NPU 的访存特性，特征图在输入预测头前首先通过一个共享的 Stem 卷积层（单个 3x3 卷积）进行通道数压缩（由 256 通道压缩至 64 通道）。随后，9 个独立的多任务预测头均直接采用 1x1 卷积在 64 通道特征图上进行目标属性的回归与分类输出。9 个输出头结构设计如下：

预测头	输出通道数	含义
hm	3	目标中心点热力图，3个通道对应 Car、Pedestrian、Cyclist
wh	2	2D 检测框的宽和高
reg	2	中心点亚像素偏移量
hps	18	9 个投影关键点的 x/y 偏移量
hm_hp	9	9 个投影关键点各自的置信度热力图
dim	3	3D 尺寸（长、宽、高）的残差
rot	8	朝向角编码（多 bin 分类与回归）
prob	1	检测质量置信度
hp_offset	2	关键点投影的亚像素偏移量

模型输入尺寸为 512×1696（保持了原图 1920×1080 的宽高比），输出特征图尺寸为 128×424。

（4）3D 坐标解算原理

N-RTM3D 的核心物理逻辑是：不直接回归深度，而是预测 3D 包围框 9 个特征点在 2D 图像上的投影位置。已知这些 2D 投影坐标、3D 尺寸和相机内参矩阵 K 后，可以建立透视投影方程组：

$$A \cdot P = B$$

其中 A 由相机内参和 2D 关键点坐标构成， P 是待求的 3D 空间位置， B 由已知几何量构成。由于 9 个投影点提供了超定约束，通过最小二乘法求解：

$$P = (A^T A)^{-1} A^T B$$

在代码实现中，后处理利用车顶的 5 个可见点，使用 NumPy 批量矩阵运算求解，从而避免逐个目标串行循环造成的耗时。

2.3.3 图像预处理模块

预处理分为两步：

- 图像增强：**根据配置评估图像的亮度、对比度和清晰度。针对暗光场景，在 LAB 色彩空间的 L 通道上施加 CLAHE（对比度受限的自适应直方图均衡化），同时进行自动白平衡校正，以改善输入信噪比。
- 尺寸归一化：**将图像按比例缩放并填充（Letterbox）到模型输入的 512×1696 尺寸，保证图像宽高比无畸变。

2.3.4 后处理与跟踪模块


NPU 输出 9 组特征图后，CPU 端的后处理流程为：

- 对热力图做 Sigmoid 激活，提取置信度最高的 Top-K 个候选目标。
- 根据回归偏移量还原 2D 检测框、9 个投影点坐标、3D 尺寸和朝向。
- 利用相机内参，自适应筛选车顶的 5 个可见投影关键点批量构建超定方程并计算 3D 空间坐标。
- 对检测结果执行 IoU 阈值为 0.5 的非极大值抑制（NMS）去重。
- 使用基于 IoU 匹配的轻量化跟踪器（SimpleTracker）维护目标 ID 的时空一致性。

第三部分 完成情况及性能参数

3.1 整体介绍


系统已在 ELF-RV1126B 板端完成了全部功能的部署和测试（本项目未采用自定义机械以及电路设计）。下面从工程成果、特性成果、系统稳定性、功耗四个方面展示实际表现。



图：开发板实物图

3.2 工程成果

开发板通过 MIPI-DSI 接口连接 7 寸 LCD 屏运行的实物效果如下图所示，系统能够流畅显示包含 3D 检测框和 BEV 鸟瞰图在内的监控 Dashboard：




图：MIPI 运行

3.3 特性成果

3.3.1 置信度阈值扫描

我们在 DAIR-V2X 路侧验证集上，对不同的检测置信度阈值进行了扫描评估。下图展示了 N-RTM3D 的精确率、召回率和 F1-Score 随阈值的变化趋势：



图：PR 曲线

对比扫频结果汇总如下表所示：


模型与置信度配置	运行帧率 (FPS)	精确率	召回率	F1-Score
0.15	3.46	61.45%	92.01%	73.69%
0.20	3.70	71.95%	90.33%	80.10%
0.25	3.71	81.27%	87.62%	84.32%
0.30	3.78	86.27%	85.32%	85.79%
0.35	3.60	92.36%	80.45%	86.00%
0.40	3.81	95.49%	75.45%	84.29%

性能与硬件瓶颈分析：

从扫频数据中可以观察到，系统的各项指标（精确率、召回率、F1-Score 和运行帧率）与置信度阈值密切相关。随着置信度阈值的升高，系统的精确率单调上升，从 61.45% 提升至 95.49%；而召回率则单调下降，从 92.01% 降至 75.45%。在阈值 $\text{conf}=0.35$ 时，系统的 F1-Score 达到峰值 86.00%。同时，系统综合吞吐帧率表现平稳，维持在 3.46 FPS 至 3.81 FPS 之间。由于本系统整体在板载 NPU 上执行高效的 INT8 量化推理，主要的计算开销已被固化于硬件单元中。当置信度阈值较低时（如 $\text{conf}=0.15$ ），系统产出的检测框数量较多（21.8 个/帧），CPU 进行批量 3D 几何求解与 IoU NMS 的开销略微增加，导致帧率小幅降至 3.46 FPS；而当阈值提升至 $\text{conf}=0.40$ 时，筛选出的检测框数量缩减至 11.5 个/帧，CPU 后处理开销降低，吞吐帧率回升至 3.81FPS。这表明，ResNet-18 骨干网络配合共享 Stem 的重构设计，能够很好地兼顾板端实时性要求与 3D 感知精度的双重需求。

3.3.2 分距离段性能分析

不同距离范围内的检测表现存在差异。下图分三个距离段统计了召回率和平均测距误差：



图：距离分析

距离段	召回率	平均测距误差
近（0-30m）	87.25%	1.47 m
中（30-50m）	96.44%	4.31 m
远（50m+）	86.22%	16.64 m

测试表明：


近距离区域（0-30m）表现最佳，召回率 87.25%，测距误差为 1.47 米，漏检率较低。该区域也是路口感知的核心关注区域。

中距离区域（30-50m）精确率为 97.24%，召回率为 96.44%，测距误差为 4.31 米。


远距离区域（50m+）由于目标成像面积较小，受图像分辨率限制，召回率降至 86.22%，平均测距误差增至 16.64 米。

3.3.3 复杂光照下性能分析


下面展示系统在不同场景下的检测效果。每组图从左到右依次为：原图、CLAHE 增强后的图、3D 检测结果叠加图、NPU 热力图可视化。




图：白天场景1



图：白天场景2



图：夜间场景1



图：夜间场景2


从夜间场景的对比中可以看到，CLAHE 预处理增强（第二列）在暗部细节和车辆轮廓上有明显改善，使 NPU 能更准确地回归投影位置。

3.3.4 延迟分析

系统端到端纯算法运算延迟为 235.6ms（综合吞吐延迟为 275.5ms），各阶段耗时占比如下：

RTM3D Pipeline Average Latency Breakdown

(Total: 235.6 ms)



图：延迟分析


阶段	平均耗时	占比
图像预处理（CLAHE + 缩放）	10.0 ms	4.2%
NPU 推理	189.7 ms	80.5%
CPU 后处理（3D 解算 + 跟踪）	35.9 ms	15.3%
合计	235.6 ms	100%

延迟统计表明：算法端到端时延中位数为 235.6ms，P99 延迟为 245.8ms，最大时延抖动仅 10.2ms，运行时延表现平稳。其中，NPU 推理占总耗时的 80.5%，是主要的时间开销。

3.3.5 系统稳定性测试

3.3.5.1 温度稳定性

系统在持续满载运行下，通过 SoC 热传感器记录的芯片温度变化如下：



图：温度曲线

- 起始温度：41.0°C（空载）
- 峰值温度：61.5°C（运行约 2 分钟后出现）
- 稳态温度：约 58.4°C（运行 10 分钟后趋于稳定）

- 距 80°C 降频阈值还有约 20°C 余量，散热表现良好。

3.3.5.2 资源占用

运行时的资源监控表明系统占用情况稳定：

```
top - 17:50:24 up 2:51, 5 users, load average: 0.69, 0.29, 0.21
Tasks: 184 total, 2 running, 182 sleeping, 0 stopped, 0 zombie
%Cpu(s): 11.7 us, 2.0 sy, 0.0 ni, 86.2 id, 0.0 wa, 0.0 hi, 0.1 si, 0.0 st
MiB Mem : 3942.0 total, 2704.3 free, 591.6 used, 782.9 buff/cache
MiB Swap: 0.0 total, 0.0 free, 0.0 used, 3350.4 avail Mem
```

PID	USER	PR	NI	VIRT	RES	SHR	S	%CPU	%MEM	TIME+	COMMAND
65060	root	1	-19	851040	184756	53220	R	51.3	4.6	0:23.29	python3

图：CPU 占用

- CPU 占用：单核占用稳定在 51% 左右，折合四核总算力约 12.7%，有较充足的算力冗余。
- 内存占用：3.8%-4.6%（约 150-180MB），无内存泄漏迹象。

3.3.6 功耗

整板功耗通过 USB 功率计实测，结果如下表所示。待机状态下功耗约 1.9W（5V/0.38A），算法全速运行时功耗约 3.4W（5V/0.68A），整板功耗控制在较低水平，适合路口杆件等户外长时间部署场景。

状态	电压	电流	功耗
待机（未运行算法）	5.0V	0.38A	1.9W
满载（算法全速运行）	5.0V	0.68A	3.4W

第四部分 总结

4.1 可改进之处

- 优化模型推理速度：**当前端到端运行速度主要受限于 NPU 的推理时延。未来改进可考虑引入结构重参数化模型（如 RepVGG 或 MobileOne），或对现有 ResNet-18 进行结构化通道剪枝，在推理时使用标准密集卷积以减少 NPU 访存瓶颈。
- 基于 C++ 语言重构：**当前推理流水线由 Python 编写，后续可将其改写为 C++，并利用瑞芯微底层的 RGA（Raster Graphic Acceleration）加速器执行图像裁剪与前处理，以进一步压缩数据搬运时延。
- 多相机视场拼接：**目前系统仅支持单路视感知。后续计划通过单应性矩阵将多路摄像头的鸟瞰图进行空间拼接，构建更大监控范围的交通态势图。

4.2 心得体会

回顾本项目的研发过程，我们意识到在嵌入式边缘设备上算法落地，不能仅依赖于 PC 端软件层面的理论数据评估。

在项目初期的模型选择中，我们曾尝试使用计算量与参数量更小的 MobileNetV2 结构，以期望获得更高的板端运行帧率。但在 ELF-RV1126B 平台实测时发现，由于其频繁的深度可分离卷积（DW-Conv）导致访存计算比偏低，NPU 芯片大部分时间处于等待内存总线读写的 Stall 状态。针对这一访存带宽瓶颈，我们调整了优化策略，放弃了 MobileNetV2 方案，转而优化 ResNet-18 结构，并通过增

加共享 Stem 卷积层将特征通道从 256 压缩至 64，从而有效降低了后续 9 路解耦头的访存压力。这表明边缘端网络设计必须契合芯片底层的访存特征，而非盲目追求理论上的轻量化。

在解决 CPU 计算瓶颈时也经历了类似的优化过程。由于单帧画面内通常包含多个检测目标，采用传统的串行循环进行 3D 几何方程求解会导致 CPU 面临明显的计算时延。为此，我们改用 NumPy 矩阵运算将解算过程进行向量化重构，实现多目标并行求解，成功将后处理时间压缩至 35.9ms。此外，针对高空路侧俯视视角下车辆底部易受光影和遮挡干扰的问题，我们在后处理解算中主动过滤了底部 4 个噪声顶点，仅利用相对稳定且信噪比较高的车顶 4 个角点和中心点（共 5 个关键点）构建投影方程组。近区深度误差因此从 1.91 米降至 1.46 米，验证了结合领域先验几何约束在算力受限边缘端的重要价值。

最后是系统工程的整体完备性整合。一个实际落地的边缘感知系统并非仅限于模型的高效推理，而是包含预处理、核心推理、后处理解算、多目标跟踪以及下游流量与速度统计等多个业务模块的闭环。在项目后期，我们投入了大量精力调试 7 寸 MIPI 屏幕硬件显示、编写 CLAHE 自适应图像增强算法，并开发车流量统计与 BEV 网格拥堵度分析等应用。当系统最终在 3.4W 的低功耗与 58.4° C 的稳态温度下实现全流水线稳定运行，并将开源仓库完整部署上线时，我们深刻认识到，软硬件的系统整合与协同联调，和算法模型开发本身具有同等重要的工程价值。

第五部分 参考文献

1. Li P, Zhao H, Liu P, et al. RTM3D: Real-time Monocular 3D Detection from Object Keypoints for Autonomous Driving[C]//Proceedings of the European Conference on Computer Vision (ECCV). Glasgow: Springer, 2020: 1-19.
2. Mousavian A, Anguelov D, Flynn J, et al. 3D Bounding Box Estimation Using Deep Learning and Geometry[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu: IEEE, 2017: 7074-7082.
3. Yu H, Luo Y, Shu M, et al. DAIR-V2X: A Large-Scale Dataset for Vehicle-Infrastructure Cooperative 3D Object Detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans: IEEE, 2022: 21358-21368.
4. Zhou X, Wang D, Krähenbühl P. Objects as Points[J]. arXiv preprint arXiv:1904.07850, 2019.
5. Ding X, Zhang X, Ma N, et al. RepVGG: Making VGG-style ConvNets Great Again[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville: IEEE, 2021: 13733-13742.
6. He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 770-778.
7. Pizer S M, Amburn E P, Austin J D, et al. Adaptive Histogram Equalization and Its Variations[J]. Computer Vision, Graphics, and Image Processing, 1987, 39(3): 355-368.
8. Bewley A, Ge Z, Ott L, et al. Simple Online and Realtime Tracking[C]//Proceedings of the IEEE International Conference on Image Processing (ICIP). Phoenix: IEEE, 2016: 3464-3468.
9. Jacob B, Kligys S, Chen B, et al. Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Salt Lake City: IEEE, 2018: 2704-2713.



10. Vasu P K A, Seneviratne J, Shen D, et al. MobileOne: An Improved One millisecond Mobile Backbone[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver: IEEE, 2023: 7907-7917.